

Big Data para Negocios

# Capturas de la ejecución del notebook

Análisis estadístico descriptivo de un inventario de productos

Conjunto de datos: Online Retail II (UCI), publicado en Kaggle

## Equipo 2: Inventario de productos

Héctor Oropeza

Diego Lara

Jorge Alvarez

Profesor: Abel Soto

7 de octubre de 2026

Archivo ejecutado: notebooks/analisis\_online\_retail.ipynb

Ejecución completa en Jupyter Notebook (Kernel, Restart Kernel and Run All Cells)

# Índice de capturas

|                                                                                   |    |
|-----------------------------------------------------------------------------------|----|
| Captura 1. Librerías, rutas y obtención de los datos                              | 3  |
| Captura 2. Verificación del archivo original y carga de datos                     | 4  |
| Captura 3. Estructura de los datos originales                                     | 5  |
| Captura 4. Diagnóstico de calidad de los datos originales                         | 6  |
| Captura 5. Normalización de texto y función de bitácora                           | 7  |
| Captura 6. Duplicados, ajustes contables y detección de compras revertidas        | 8  |
| Captura 7. Resto de reglas de limpieza y bitácora                                 | 9  |
| Captura 8. Columna Total y verificación del conjunto limpio                       | 10 |
| Captura 9. Muestra del conjunto limpio y archivos guardados                       | 11 |
| Captura 10. Medidas de tendencia central y de dispersión                          | 12 |
| Captura 11. Frecuencia de la moda y valores atípicos (regla de $1.5 \times IQR$ ) | 13 |
| Captura 12. Matriz de covarianza y correlaciones de Pearson y Spearman            | 14 |
| Captura 13. Estadísticos y correlación a nivel producto                           | 15 |
| Captura 14. Configuración de estilo para las gráficas                             | 16 |
| Captura 15. Figura 1. Histograma de frecuencias de Quantity                       | 17 |
| Captura 16. Figura 2. Histograma y curva de densidad de Price                     | 18 |
| Captura 17. Figura 3. Curva de densidad de Total en escala logarítmica            | 19 |
| Captura 18. Figura 4. Diagramas de caja y bigotes                                 | 20 |
| Captura 19. Figura 5. Dispersión entre unidades vendidas e ingreso por producto   | 21 |
| Captura 20. Figura 6. Ingreso mensual                                             | 22 |
| Captura 21. Figura 7. Diez productos con mayor ingreso                            | 23 |
| Captura 22. Figura 8. Ingreso por país (sin Reino Unido)                          | 24 |
| Captura 23. Figura 9. Mapa de calor de la correlación de Spearman por producto    | 25 |
| Captura 24. Figura 10. Concentración del ingreso por producto (curva de Pareto)   | 26 |
| Captura 25. Validación final de resultados                                        | 27 |

## Captura 1. Librerías, rutas y obtención de los datos

```
[1]: # Captura 1: Librerías, rutas y obtención de Los datos
import hashlib
import io
import sys
import urllib.request
import zipfile
from pathlib import Path

import numpy as np
import pandas as pd
import scipy
import matplotlib

EN_COLAB = "google.colab" in sys.modules

# Rutas del proyecto: funciona desde la carpeta notebooks, desde la raíz del repositorio o en Colab
ROOT = Path.cwd().parent if Path.cwd().name == "notebooks" else Path.cwd()
RAW = ROOT / "data" / "raw" / "online_retail.csv"
PROCESSED = ROOT / "data" / "processed" / "online_retail_clean.csv"
TABLES = ROOT / "outputs" / "tables"
FIGURES = ROOT / "outputs" / "figures"
for carpeta in [RAW.parent, PROCESSED.parent, TABLES, FIGURES]:
    carpeta.mkdir(parents=True, exist_ok=True)

# Si el archivo original no está (por ejemplo, en Colab), se descarga de Kaggle.
# Si Kaggle no responde, se usa la copia guardada en el repositorio del equipo.
URL_KAGGLE = "https://www.kaggle.com/api/v1/datasets/download/saurabhbadole/supermarket-data"
URL_REPOSITORIO = ("https://raw.githubusercontent.com/GoldenDiegos/big-data-inventario-productos-online-retail/"
                  "main/data/raw/online_retail.csv")

if not RAW.exists():
    try:
        print("Descargando el conjunto de datos desde Kaggle...")
        with urllib.request.urlopen(URL_KAGGLE, timeout=60) as respuesta:
            with zipfile.ZipFile(io.BytesIO(respuesta.read())) as z:
                RAW.write_bytes(z.read("supermarket_data.csv"))
    except Exception as error:
        print("Kaggle no respondió (", error, "). Descargando la copia del repositorio...")
        with urllib.request.urlopen(URL_REPOSITORIO, timeout=120) as respuesta:
            RAW.write_bytes(respuesta.read())

pd.set_option("display.max_columns", None)
pd.set_option("display.width", 160)

print("Entorno:", "Google Colab" if EN_COLAB else "local")
print("Python", sys.version.split()[0], "| pandas", pd.__version__, "| numpy", np.__version__,
      "| scipy", scipy.__version__, "| matplotlib", matplotlib.__version__)
print("Archivo de datos:", RAW.relative_to(ROOT).as_posix())

Entorno: local
Python 3.14.3 | pandas 3.0.6 | numpy 2.5.3 | scipy 1.18.1 | matplotlib 3.11.2
Archivo de datos: data/raw/online_retail.csv
```

## Captura 2. Verificación del archivo original y carga de datos

```
[2]: # Captura 2: Verificación del archivo original y carga de datos
SHA256_ORIGINAL = "cb304b33513787ba84fc0e7d38b21f49279f6817e48f99d6d3cc3a849cc436ca"
sha = hashlib.sha256(RAW.read_bytes()).hexdigest()
assert sha == SHA256_ORIGINAL, "El archivo original fue modificado"
print("Huella SHA-256 verificada:", sha)

raw = pd.read_csv(RAW, dtype={"Invoice": str, "StockCode": str, "Customer ID": "Int64"})
print(f"Filas: {raw.shape[0]:,} Columnas: {raw.shape[1]:,}")
raw.head(10)

Huella SHA-256 verificada: cb304b33513787ba84fc0e7d38b21f49279f6817e48f99d6d3cc3a849cc436ca
Filas: 541,910 Columnas: 8
```

```
[2]:
```

|   | Invoice | StockCode | Description                         | Quantity | InvoiceDate    | Price | Customer ID | Country        |
|---|---------|-----------|-------------------------------------|----------|----------------|-------|-------------|----------------|
| 0 | 536365  | 85123A    | WHITE HANGING HEART T-LIGHT HOLDER  | 6        | 01/12/10 08:26 | 2.55  | 17850       | United Kingdom |
| 1 | 536365  | 71053     | WHITE METAL LANTERN                 | 6        | 01/12/10 08:26 | 3.39  | 17850       | United Kingdom |
| 2 | 536365  | 84406B    | CREAM CUPID HEARTS COAT HANGER      | 8        | 01/12/10 08:26 | 2.75  | 17850       | United Kingdom |
| 3 | 536365  | 84029G    | KNITTED UNION FLAG HOT WATER BOTTLE | 6        | 01/12/10 08:26 | 3.39  | 17850       | United Kingdom |
| 4 | 536365  | 84029E    | RED WOOLLY HOTTIE WHITE HEART.      | 6        | 01/12/10 08:26 | 3.39  | 17850       | United Kingdom |
| 5 | 536365  | 22752     | SET 7 BABUSHKA NESTING BOXES        | 2        | 01/12/10 08:26 | 7.65  | 17850       | United Kingdom |
| 6 | 536365  | 21730     | GLASS STAR FROSTED T-LIGHT HOLDER   | 6        | 01/12/10 08:26 | 4.25  | 17850       | United Kingdom |
| 7 | 536366  | 22633     | HAND WARMER UNION JACK              | 6        | 01/12/10 08:28 | 1.85  | 17850       | United Kingdom |
| 8 | 536366  | 22632     | HAND WARMER RED POLKA DOT           | 6        | 01/12/10 08:28 | 1.85  | 17850       | United Kingdom |
| 9 | 536368  | 22960     | JAM MAKING SET WITH JARS            | 6        | 01/12/10 08:34 | 4.25  | 13047       | United Kingdom |

### Captura 3. Estructura de los datos originales

```
[3]: # Captura 3: Estructura de Los datos originales
estructura = pd.DataFrame({
    "Tipo": raw.dtypes.astype(str),
    "Valores nulos": raw.isna().sum(),
    "% nulos": (raw.isna().mean() * 100).round(2),
    "Valores únicos": raw.nunique(),
})
estructura
```

```
[3]:
```

|             | Tipo    | Valores nulos | % nulos | Valores únicos |
|-------------|---------|---------------|---------|----------------|
| Invoice     | str     | 0             | 0.00    | 25900          |
| StockCode   | str     | 0             | 0.00    | 4070           |
| Description | str     | 1454          | 0.27    | 4223           |
| Quantity    | int64   | 0             | 0.00    | 722            |
| InvoiceDate | str     | 0             | 0.00    | 23260          |
| Price       | float64 | 0             | 0.00    | 1630           |
| Customer ID | int64   | 135080        | 24.93   | 4372           |
| Country     | str     | 0             | 0.00    | 38             |

## Captura 4. Diagnóstico de calidad de los datos originales

```
[4]: # Captura 4: Diagnóstico de calidad de Los datos originales
SERVICIOS = ["POST", "DOT", "M", "C2", "D", "S", "BANK CHARGES", "AMAZONFEE", "CRUK", "B", "PADS",
            "23444", "23702", "22016"] # envío al día siguiente, imagen digital, vale de regalo de £100
codigo = raw["StockCode"].str.strip().str.upper()
desc = raw["Description"]

diagnostico = pd.DataFrame([
    ("Filas duplicadas exactas", raw.duplicated().sum()),
    ("Facturas canceladas (prefijo C)", raw["Invoice"].str.startswith("C").sum()),
    ("Ajustes contables (prefijo A)", raw["Invoice"].str.startswith("A").sum()),
    ("Cantidad menor o igual a 0", (raw["Quantity"] <= 0).sum()),
    ("Precio menor o igual a 0", (raw["Price"] <= 0).sum()),
    ("Códigos de servicio o vales de regalo", (codigo.isin(SERVICIOS) | codigo.str.startswith("GIFT_")).sum()),
    ("Descripción vacía", desc.isna().sum()),
    ("Descripción con espacios sobrantes", (desc.notna() & (desc != desc.str.strip().str.replace(r"\s+", " ", regex=True))).sum()),
    ("Código de producto en minúsculas", raw["StockCode"].str.contains("[a-z]").sum()),
    ("Customer ID vacío", raw["Customer ID"].isna().sum()),
], columns=["Problema", "Registros"])
diagnostico.style.format({"Registros": "{:,}"})hide(axis="index")
```

| Problema                              | Registros |
|---------------------------------------|-----------|
| Filas duplicadas exactas              | 5,268     |
| Facturas canceladas (prefijo C)       | 9,288     |
| Ajustes contables (prefijo A)         | 3         |
| Cantidad menor o igual a 0            | 10,624    |
| Precio menor o igual a 0              | 2,517     |
| Códigos de servicio o vales de regalo | 3,037     |
| Descripción vacía                     | 1,454     |
| Descripción con espacios sobrantes    | 128,367   |
| Código de producto en minúsculas      | 1,977     |
| Customer ID vacío                     | 135,080   |

## Captura 5. Normalización de texto y función de bitácora

```
[5]: # Captura 5: Normalización de texto y función de bitácora
df = raw.rename(columns={"Customer ID": "CustomerID"}).copy()
df["StockCode"] = df["StockCode"].str.strip().str.upper()
df["Description"] = df["Description"].str.strip().str.replace(r"\s+", " ", regex=True)
df["InvoiceDate"] = pd.to_datetime(df["InvoiceDate"], format="%d/%m/%y %H:%M")

# Un mismo código puede tener variantes de nombre ("DOILY" y "DOILEY"). A cada código se le asigna
# la descripción más frecuente entre sus ventas válidas (cantidad y precio mayores a 0).
ventas_validas = df[df["Description"].notna() & (df["Quantity"] > 0) & (df["Price"] > 0)
                    & ~df["Invoice"].str.startswith(("C", "A"))]
canonica = (ventas_validas.groupby(["StockCode", "Description"]).size().reset_index(name="n")
            .sort_values(["StockCode", "n", "Description"], ascending=[True, False, True])
            .drop_duplicates("StockCode").set_index("StockCode")["Description"])
variantes = ventas_validas.groupby("StockCode")["Description"].nunique()
tiene_canonica = df["Description"].notna() & df["StockCode"].isin(canonica.index)
df.loc[tiene_canonica, "Description"] = df.loc[tiene_canonica, "StockCode"].map(canonica)
print(f"Códigos con variantes de nombre unificados: {(variantes > 1).sum()}")

bitacora = []

def registrar(regla, antes, despues):
    bitacora.append({
        "Paso": len(bitacora) + 1,
        "Regla": regla,
        "Filas antes": len(antes),
        "Filas después": len(despues),
        "Filas eliminadas": len(antes) - len(despues),
    })
    return despues

df = registrar("Normalización de texto y fechas", raw, df)
print(f"Rango de fechas:", df["InvoiceDate"].min(), "a", df["InvoiceDate"].max())

Códigos con variantes de nombre unificados: 207
Rango de fechas: 2010-12-01 08:26:00 a 2011-12-09 12:50:00
```

# Captura 6. Duplicados, ajustes contables y detección de compras revertidas

```
[6]: # Captura 6: Duplicados, ajustes contables y detección de compras revertidas
df = registrar("Duplicados exactos", df, df.drop_duplicates())
df = registrar("Ajustes contables (prefijo A)", df, df[~df["Invoice"].str.startswith("A")])

# Cada cancelación se empareja con la compra previa más reciente del mismo cliente,
# mismo código de producto, misma cantidad y mismo precio. Cada compra se usa una sola vez.
es_cancelacion = df["Invoice"].str.startswith("C")
cancelaciones = df[es_cancelacion & df["CustomerID"].notna()]
compras = df[~es_cancelacion & (df["Quantity"] > 0) & df["CustomerID"].notna()]

candidatos = compras.reset_index().merge(
    cancelaciones.reset_index()
    .assign(Quantity=lambda x: -x["Quantity"])
    .loc[:, ["index", "CustomerID", "StockCode", "Quantity", "Price", "InvoiceDate"]]
    .rename(columns={"index": "idx_cancelacion", "InvoiceDate": "FechaCancelacion"}),
    on=["CustomerID", "StockCode", "Quantity", "Price"],
)
candidatos = candidatos[candidatos["InvoiceDate"] <= candidatos["FechaCancelacion"]]
candidatos = candidatos.sort_values(["FechaCancelacion", "idx_cancelacion", "InvoiceDate", "index"],
    ascending=[True, True, False, False])

revertidas = []
usadas = set()
for _, grupo in candidatos.groupby("idx_cancelacion", sort=False):
    for idx in grupo["index"]:
        if idx not in usadas:
            usadas.add(idx)
            revertidas.append(idx)
        break

print(f"Compras revertidas encontradas: {len(revertidas):,}")
print(f"Unidades que no se concretaron: {df.loc[revertidas, 'Quantity'].sum():,}")
print("\nCompras revertidas con mayor cantidad:")
df.loc[revertidas].nlargest(5, "Quantity")[["Invoice", "StockCode", "Description", "Quantity", "Price", "CustomerID", "InvoiceDate"]]
```

Compras revertidas encontradas: 2,769  
Unidades que no se concretaron: 223,470

Compras revertidas con mayor cantidad:

|        | Invoice | StockCode | Description                        | Quantity | Price | CustomerID | InvoiceDate         |
|--------|---------|-----------|------------------------------------|----------|-------|------------|---------------------|
| 540421 | 581483  | 23843     | PAPER CRAFT , LITTLE BIRDIE        | 80995    | 2.08  | 16446      | 2011-12-09 09:15:00 |
| 61619  | 541431  | 23166     | MEDIUM CERAMIC TOP STORAGE JAR     | 74215    | 1.04  | 12346      | 2011-01-18 10:01:00 |
| 52711  | 540815  | 21108     | FAIRY CAKE FLANNEL ASSORTED COLOUR | 3114     | 2.10  | 15749      | 2011-01-11 12:55:00 |
| 52710  | 540815  | 21175     | GIN + TONIC DIET METAL SIGN        | 2000     | 1.85  | 15749      | 2011-01-11 12:55:00 |
| 52709  | 540815  | 85123A    | WHITE HANGING HEART T-LIGHT HOLDER | 1930     | 2.55  | 15749      | 2011-01-11 12:55:00 |

## Captura 7. Resto de reglas de limpieza y bitácora

```
[7]: # Captura 7: Resto de reglas de limpieza y bitácora
df = registrar("Compras revertidas por una cancelación", df, df.drop(index=revertidas))

# Las notas de crédito manuales (código M) se guardan antes de quitar las cancelaciones
creditos = df[df["Invoice"].str.startswith("C") & (df["StockCode"] == "M") & df["CustomerID"].notna()].copy()
creditos["Importe"] = (-creditos["Quantity"] * creditos["Price"]).round(2)

df = registrar("Facturas canceladas (prefijo C)", df, df[~df["Invoice"].str.startswith("C")])
es_servicio = df[df["StockCode"].isin(SERVICIOS) | df["StockCode"].str.startswith("GIFT_")]
df = registrar("Códigos de servicio y vales de regalo", df, df[~es_servicio])
df = registrar("Cantidad menor o igual a 0", df, df[df["Quantity"] > 0])
df = registrar("Precio menor o igual a 0", df, df[df["Price"] > 0])

# Una nota de crédito manual cuyo importe es igual, al centavo, al total de una factura previa
# del mismo cliente anula esa factura completa
facturas = (df.assign(Importe=df["Quantity"] * df["Price"])
            .groupby(["Invoice", "CustomerID"], as_index=False)
            .agg(Importe=("Importe", "sum"), Fecha=("InvoiceDate", "min")))
facturas["Importe"] = facturas["Importe"].round(2)
acreditadas = []
for _, c in creditos.sort_values("InvoiceDate").iterrows():
    opciones = facturas[(facturas["CustomerID"] == c["CustomerID"]) & (facturas["Importe"] == c["Importe"])
                        & (facturas["Fecha"] <= c["InvoiceDate"]) & ~facturas["Invoice"].isin(acreditadas)]
    if len(opciones):
        acreditadas.append(opciones.sort_values("Fecha").iloc[-1]["Invoice"])
print(f"Facturas anuladas por nota de crédito manual: {len(acreditadas)}")
df = registrar("Facturas anuladas por nota de crédito manual", df, df[~df["Invoice"].isin(acreditadas)])
df = registrar("Descripción vacía", df, df[df["Description"].notna()])

bitacora_df = pd.DataFrame(bitacora)
total = pd.DataFrame([{"Paso": "", "Regla": "Total",
                      "Filas antes": len(raw), "Filas después": len(df),
                      "Filas eliminadas": len(raw) - len(df),
                      }])
bitacora_df = pd.concat([bitacora_df, total], ignore_index=True)
bitacora_df.style.format({c: "{:,}" for c in ["Filas antes", "Filas después", "Filas eliminadas"]}).hide(axis="index")
```

Facturas anuladas por nota de crédito manual: 20

| [7]: | Paso | Regla                                        | Filas antes | Filas después | Filas eliminadas |
|------|------|----------------------------------------------|-------------|---------------|------------------|
|      | 1    | Normalización de texto y fechas              | 541,910     | 541,910       | 0                |
|      | 2    | Duplicados exactos                           | 541,910     | 536,640       | 5,270            |
|      | 3    | Ajustes contables (prefijo A)                | 536,640     | 536,637       | 3                |
|      | 4    | Compras revertidas por una cancelación       | 536,637     | 533,868       | 2,769            |
|      | 5    | Facturas canceladas (prefijo C)              | 533,868     | 524,617       | 9,251            |
|      | 6    | Códigos de servicio y vales de regalo        | 524,617     | 522,218       | 2,399            |
|      | 7    | Cantidad menor o igual a 0                   | 522,218     | 520,882       | 1,336            |
|      | 8    | Precio menor o igual a 0                     | 520,882     | 519,728       | 1,154            |
|      | 9    | Facturas anuladas por nota de crédito manual | 519,728     | 519,231       | 497              |
|      | 10   | Descripción vacía                            | 519,231     | 519,231       | 0                |
|      |      | Total                                        | 541,910     | 519,231       | 22,679           |

## Captura 8. Columna Total y verificación del conjunto limpio

```
[8]: # Captura 8: Columna Total y verificación del conjunto Limpio
df["Total"] = (df["Quantity"] * df["Price"]).round(2)
df = df.reset_index(drop=True)

assert not df.duplicated().any()
assert not df["Invoice"].str.startswith(("C", "A")).any()
assert (df["Quantity"] > 0).all() and (df["Price"] > 0).all()
assert not (df["StockCode"].isin(SERVICIOS) | df["StockCode"].str.startswith("GIFT_")).any()
assert df.drop(columns="CustomerID").notna().all().all()
assert df.groupby("StockCode")["Description"].nunique().max() == 1
print("Todas las verificaciones se cumplieron.\n")

resumen = pd.DataFrame([
    ("Filas", f"{len(df):,}"),
    ("Productos distintos (StockCode)", f"{df['StockCode'].nunique():,}"),
    ("Facturas", f"{df['Invoice'].nunique():,}"),
    ("Clientes registrados", f"{df['CustomerID'].nunique():,}"),
    ("Países", f"{df['Country'].nunique():,}"),
    ("Filas conservadas", f"{len(df) / len(raw) * 100:.2f} %"),
], columns=["Concepto", "Valor"])
display(resumen.style.hide(axis="index"))
df.info()
```

Todas las verificaciones se cumplieron.

| Concepto                        | Valor   |
|---------------------------------|---------|
| Filas                           | 519,231 |
| Productos distintos (StockCode) | 3,790   |
| Facturas                        | 19,627  |
| Clientes registrados            | 4,322   |
| Países                          | 38      |
| Filas conservadas               | 95.81 % |

```
<class 'pandas.DataFrame'>
RangeIndex: 519231 entries, 0 to 519230
Data columns (total 9 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Invoice      519231 non-null  str
1   StockCode   519231 non-null  str
2   Description  519231 non-null  str
3   Quantity    519231 non-null  int64
4   InvoiceDate  519231 non-null  datetime64[us]
5   Price       519231 non-null  float64
6   CustomerID  387845 non-null  int64
7   Country     519231 non-null  str
8   Total       519231 non-null  float64
dtypes: int64(1), datetime64[us](1), float64(2), int64(1), str(4)
memory usage: 36.1 MB
```

# Captura 9. Muestra del conjunto limpio y archivos guardados

```
[9]: # Captura 9: Muestra del conjunto limpio y archivos guardados
df.to_csv(PROCESSED, index=False, lineterminator="\n")
pd.DataFrame(bitacora).to_csv(TABLES / "cleaning_log.csv", index=False, lineterminator="\n")
diagnostico.to_csv(TABLES / "raw_quality_check.csv", index=False, lineterminator="\n")
print("Guardado:", PROCESSED.relative_to(ROOT).as_posix())
print("Guardado:", (TABLES / "cleaning_log.csv").relative_to(ROOT).as_posix())
print("Guardado:", (TABLES / "raw_quality_check.csv").relative_to(ROOT).as_posix())
df.sample(10, random_state=2)
```

Guardado: data/processed/online\_retail\_clean.csv  
Guardado: outputs/tables/cleaning\_log.csv  
Guardado: outputs/tables/raw\_quality\_check.csv

|        | Invoice | StockCode | Description                       | Quantity | InvoiceDate         | Price | CustomerID | Country        | Total |
|--------|---------|-----------|-----------------------------------|----------|---------------------|-------|------------|----------------|-------|
| 231006 | 558237  | 23208     | LUNCH BAG VINTAGE LEAF DESIGN     | 3        | 2011-06-27 15:04:00 | 1.65  | 12867      | United Kingdom | 4.95  |
| 184328 | 553485  | 23131     | MISTLETOE HEART WREATH CREAM      | 2        | 2011-05-17 12:25:00 | 4.15  | 13208      | United Kingdom | 8.30  |
| 33335  | 539434  | 21281     | VINTAGE KITCHEN PRINT SEAFOOD     | 1        | 2010-12-17 14:41:00 | 5.06  | <NA>       | United Kingdom | 5.06  |
| 480587 | 578833  | 22966     | GINGERBREAD MAN COOKIE CUTTER     | 2        | 2011-11-25 15:23:00 | 2.46  | <NA>       | United Kingdom | 4.92  |
| 392611 | 572103  | 22919     | HERB MARKER MINT                  | 4        | 2011-10-20 15:57:00 | 0.65  | 17571      | United Kingdom | 2.60  |
| 263922 | 561033  | 84380     | SET OF 3 BUTTERFLY COOKIE CUTTERS | 12       | 2011-07-24 11:40:00 | 1.25  | 14443      | United Kingdom | 15.00 |
| 325665 | 566607  | 22476     | EMPIRE UNION JACK TV DINNER TRAY  | 1        | 2011-09-13 16:40:00 | 4.95  | 13032      | United Kingdom | 4.95  |
| 180558 | 553088  | 22555     | PLASTERS IN TIN STRONGMAN         | 12       | 2011-05-13 11:53:00 | 1.65  | 16180      | United Kingdom | 19.80 |
| 31914  | 539250  | 85035C    | ROSE 3 WICK MORRIS BOX CANDLE     | 12       | 2010-12-16 13:44:00 | 1.25  | 15157      | United Kingdom | 15.00 |
| 512808 | 581214  | 21791     | VINTAGE HEADS AND TAILS CARD GAME | 12       | 2011-12-08 08:32:00 | 1.25  | 14251      | United Kingdom | 15.00 |

## Captura 10. Medidas de tendencia central y de dispersión

```
[10]: # Captura 10: Medidas de tendencia central y de dispersión
from scipy import stats

VARIABLES = ["Quantity", "Price", "Total"]

def medidas_pandas(s):
    q1, q3 = s.quantile(0.25), s.quantile(0.75)
    return {
        "Observaciones": s.count(),
        "Media": s.mean(),
        "Mediana": s.median(),
        "Moda": s.mode().iloc[0],
        "Mínimo": s.min(),
        "Primer cuartil (Q1)": q1,
        "Tercer cuartil (Q3)": q3,
        "Rango intercuartílico (IQR)": q3 - q1,
        "Máximo": s.max(),
        "Rango": s.max() - s.min(),
        "Varianza": s.var(),
        "Desviación estándar": s.std(),
        "Coeficiente de variación (%)": s.std() / s.mean() * 100,
        "Asimetría": s.skew(),
    }

def medidas_numpy(s):
    x = s.to_numpy(dtype=float)
    q1, q3 = np.percentile(x, [25, 75])
    return {
        "Observaciones": x.size,
        "Media": np.mean(x),
        "Mediana": np.median(x),
        "Moda": stats.mode(x, keepdims=False).mode,
        "Mínimo": np.min(x),
        "Primer cuartil (Q1)": q1,
        "Tercer cuartil (Q3)": q3,
        "Rango intercuartílico (IQR)": stats.iqr(x),
        "Máximo": np.max(x),
        "Rango": np.ptp(x),
        "Varianza": np.var(x, ddof=1),
        "Desviación estándar": np.std(x, ddof=1),
        "Coeficiente de variación (%)": stats.variation(x, ddof=1) * 100,
        "Asimetría": stats.skew(x, bias=False),
    }

estadisticos = pd.DataFrame({v: medidas_pandas(df[v]) for v in VARIABLES})
comprobacion = pd.DataFrame({v: medidas_numpy(df[v]) for v in VARIABLES})
assert np.allclose(estadisticos.astype(float), comprobacion.astype(float), rtol=1e-9), "Los dos cálculos no coinciden"
print("Los cálculos con pandas y con numpy/scipy coinciden en todas las medidas.\n")

estadisticos.round(4).to_csv(TABLES / "descriptive_stats.csv", lineterminator="\n")
estadisticos.style.format("{:,.2f}").format("{:,.0f}", subset=pd.IndexSlice[:, "Observaciones"], :])

Los cálculos con pandas y con numpy/scipy coinciden en todas las medidas.
```

```
[10]:
```

|                                     | Quantity | Price   | Total    |
|-------------------------------------|----------|---------|----------|
| <b>Observaciones</b>                | 519,231  | 519,231 | 519,231  |
| <b>Media</b>                        | 10.25    | 3.26    | 18.87    |
| <b>Mediana</b>                      | 4.00     | 2.08    | 9.90     |
| <b>Moda</b>                         | 1.00     | 1.25    | 15.00    |
| <b>Mínimo</b>                       | 1.00     | 0.04    | 0.06     |
| <b>Primer cuartil (Q1)</b>          | 1.00     | 1.25    | 3.90     |
| <b>Tercer cuartil (Q3)</b>          | 11.00    | 4.13    | 17.70    |
| <b>Rango intercuartílico (IQR)</b>  | 10.00    | 2.88    | 13.80    |
| <b>Máximo</b>                       | 4,800.00 | 649.50  | 7,144.72 |
| <b>Rango</b>                        | 4,799.00 | 649.46  | 7,144.66 |
| <b>Varianza</b>                     | 1,365.18 | 17.62   | 3,981.71 |
| <b>Desviación estándar</b>          | 36.95    | 4.20    | 63.10    |
| <b>Coeficiente de variación (%)</b> | 360.37   | 128.75  | 334.36   |
| <b>Asimetría</b>                    | 33.43    | 20.37   | 30.28    |

## Captura 11. Frecuencia de la moda y valores atípicos (regla de $1.5 \times IQR$ )

```
[11]: # Captura 11: Frecuencia de la moda y valores atípicos (regla de  $1.5 \times IQR$ )
      filas = []
      for v in VARIABLES:
          s = df[v]
          q1, q3 = s.quantile(0.25), s.quantile(0.75)
          iqr = q3 - q1
          lim_inf, lim_sup = q1 - 1.5 * iqr, q3 + 1.5 * iqr
          atipicos = ((s < lim_inf) | (s > lim_sup)).sum()
          moda = s.mode().iloc[0]
          filas.append({
              "Variable": v,
              "Moda": moda,
              "Veces que aparece la moda": (s == moda).sum(),
              "Límite inferior": lim_inf,
              "Límite superior": lim_sup,
              "Valores atípicos": atipicos,
              "% atípicos": atipicos / len(s) * 100,
          })
      atipicos_df = pd.DataFrame(filas)
      atipicos_df.round(4).to_csv(TABLES / "outliers_iqr.csv", index=False, lineterminator="\n")
      atipicos_df.style.format({
          "Moda": "{:,.2f}", "Veces que aparece la moda": "{:}", "Límite inferior": "{:,.2f}",
          "Límite superior": "{:,.2f}", "Valores atípicos": "{:}", "% atípicos": "{:,.2f}",
      }).hide(axis="index")
```

```
[11]:
```

| Variable | Moda  | Veces que aparece la moda | Límite inferior | Límite superior | Valores atípicos | % atípicos |
|----------|-------|---------------------------|-----------------|-----------------|------------------|------------|
| Quantity | 1.00  | 141,912                   | -14.00          | 26.00           | 26,663           | 5.14       |
| Price    | 1.25  | 48,678                    | -3.07           | 8.45            | 35,178           | 6.78       |
| Total    | 15.00 | 19,871                    | -16.80          | 38.40           | 40,482           | 7.80       |

## Captura 12. Matriz de covarianza y correlaciones de Pearson y Spearman

```
[12]: # Captura 12: Matriz de covarianza y correlaciones de Pearson y Spearman
covarianza = df[VARIABLES].cov()
pearson = df[VARIABLES].corr(method="pearson")
spearman = df[VARIABLES].corr(method="spearman")

# Comprobación independiente con numpy y scipy
assert np.allclose(covarianza, np.cov(df[VARIABLES].to_numpy(dtype=float), rowvar=False))
assert np.allclose(pearson, np.corrcoef(df[VARIABLES].to_numpy(dtype=float), rowvar=False))
assert np.allclose(spearman, stats.spearmanr(df[VARIABLES])[0])

covarianza.round(4).to_csv(TABLES / "covariance.csv", lineterminator="\n")
pd.concat({"Pearson": pearson, "Spearman": spearman}).round(4).to_csv(TABLES / "correlation.csv", lineterminator="\n")

display(covarianza.style.format("{:,.2f}").set_caption("Matriz de covarianza"))
display(pearson.style.format("{:.3f}").set_caption("Correlación de Pearson"))
display(spearman.style.format("{:.3f}").set_caption("Correlación de Spearman"))
```

Matriz de covarianza

|          | Quantity | Price  | Total    |
|----------|----------|--------|----------|
| Quantity | 1,365.18 | -14.55 | 1,518.04 |
| Price    | -14.55   | 17.62  | 24.36    |
| Total    | 1,518.04 | 24.36  | 3,981.71 |

Correlación de Pearson

|          | Quantity | Price  | Total |
|----------|----------|--------|-------|
| Quantity | 1.000    | -0.094 | 0.651 |
| Price    | -0.094   | 1.000  | 0.092 |
| Total    | 0.651    | 0.092  | 1.000 |

Correlación de Spearman

|          | Quantity | Price  | Total |
|----------|----------|--------|-------|
| Quantity | 1.000    | -0.406 | 0.684 |
| Price    | -0.406   | 1.000  | 0.329 |
| Total    | 0.684    | 0.329  | 1.000 |

# Captura 13. Estadísticos y correlación a nivel producto

```
[13]: # Captura 13: Estadísticos y correlación a nivel producto
productos = df.groupby("StockCode").agg(
    Description=("Description", "first"),
    Unidades=("Quantity", "sum"),
    Facturas=("Invoice", "nunique"),
    PrecioMediano=("Price", "median"),
    Ingreso=("Total", "sum"),
)
productos.round(2).to_csv(TABLES / "product_summary.csv", lineterminator="\n")

columnas = ["Unidades", "Facturas", "PrecioMediano", "Ingreso"]
resumen_productos = pd.DataFrame({c: medidas_pandas(productos[c]) for c in columnas})
# La moda no se reporta a nivel producto: el ingreso más repetido aparece solo en 8 de 3,790 productos
resumen_productos = resumen_productos.drop(index="Moda")
resumen_productos.round(4).to_csv(TABLES / "product_stats.csv", lineterminator="\n")

acumulado = productos["Ingreso"].sort_values(ascending=False).cumsum() / productos["Ingreso"].sum()
n_80 = int((acumulado < 0.80).sum() + 1)
print(f"Productos analizados: {len(productos):,}")
print(f"Productos que generan el 80 % del ingreso: {n_80:,} ({n_80 / len(productos) * 100:.1f} %)\n")

corr_productos = productos[columnas].corr(method="spearman")
corr_productos.round(4).to_csv(TABLES / "product_correlation_spearman.csv", lineterminator="\n")
display(resumen_productos.style.format("{:,.2f}").format("{:,.0f}", subset=pd.IndexSlice[["Observaciones"], :])
        .set_caption("Estadísticos por producto"))
display(corr_productos.style.format("{:.3f}").set_caption("Correlación de Spearman entre variables de producto"))
```

Productos analizados: 3,790

Productos que generan el 80 % del ingreso: 834 (22.0 %)

Estadísticos por producto

|                                      | Unidades     | Facturas  | PrecioMediano | Ingreso       |
|--------------------------------------|--------------|-----------|---------------|---------------|
| <b>Observaciones</b>                 | 3,790        | 3,790     | 3,790         | 3,790         |
| <b>Media</b>                         | 1,404.65     | 135.63    | 3.47          | 2,585.48      |
| <b>Mediana</b>                       | 404.50       | 69.00     | 2.08          | 710.23        |
| <b>Mínimo</b>                        | 1.00         | 1.00      | 0.04          | 0.42          |
| <b>Primer cuartil (Q1)</b>           | 65.25        | 18.00     | 1.00          | 142.92        |
| <b>Tercer cuartil (Q3)</b>           | 1,437.75     | 170.00    | 4.13          | 2,270.67      |
| <b>Rango intercuartílico (IQR)</b>   | 1,372.50     | 152.00    | 3.13          | 2,127.75      |
| <b>Máximo</b>                        | 56,476.00    | 2,250.00  | 165.00        | 169,901.19    |
| <b>Rango</b>                         | 56,475.00    | 2,249.00  | 164.96        | 169,900.77    |
| <b>Varianza</b>                      | 9,707,852.68 | 37,875.72 | 45.57         | 40,696,460.57 |
| <b>Desviación estándar</b>           | 3,115.74     | 194.62    | 6.75          | 6,379.38      |
| <b>Coefficiente de variación (%)</b> | 221.82       | 143.50    | 194.38        | 246.74        |
| <b>Asimetría</b>                     | 7.14         | 3.36      | 13.77         | 9.78          |

Correlación de Spearman entre variables de producto

|                      | Unidades | Facturas | PrecioMediano | Ingreso |
|----------------------|----------|----------|---------------|---------|
| <b>Unidades</b>      | 1.000    | 0.917    | -0.364        | 0.867   |
| <b>Facturas</b>      | 0.917    | 1.000    | -0.127        | 0.925   |
| <b>PrecioMediano</b> | -0.364   | -0.127   | 1.000         | 0.090   |
| <b>Ingreso</b>       | 0.867    | 0.925    | 0.090         | 1.000   |

## Captura 14. Configuración de estilo para las gráficas

```
[14]: # Captura 14: Configuración de estilo para las gráficas
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
from matplotlib.lines import Line2D
from string import capwords

# Colores estándar de matplotlib
AZUL = "tab:blue"
AZUL_CLARO = "#aec7e8" # azul claro de la paleta tab20
NARANJA = "tab:orange"
NEGRO = "black"
GRIS_OSCURO = "dimgray"
GRIS = "gray"
GRIS_CLARO = "gainsboro"

plt.rcParams.update({
    "font.family": "sans-serif",
    "font.sans-serif": ["Segoe UI", "Liberation Sans", "DejaVu Sans"],
    "font.size": 10,
    "axes.unicode_minus": False,
    "figure.facecolor": "white",
    "axes.facecolor": "white",
    "axes.edgecolor": "darkgray",
    "axes.linewidth": 0.8,
    "axes.labelcolor": GRIS_OSCURO,
    "axes.titlesize": 13,
    "axes.titleweight": "semibold",
    "axes.titlecolor": NEGRO,
    "axes.titlelocation": "left",
    "axes.titlepad": 12,
    "axes.spines.top": False,
    "axes.spines.right": False,
    "axes.grid": True,
    "axes.axisbelow": True,
    "grid.color": GRIS_CLARO,
    "grid.linewidth": 0.6,
    "xtick.color": GRIS,
    "ytick.color": GRIS,
    "xtick.labelcolor": GRIS_OSCURO,
    "ytick.labelcolor": GRIS_OSCURO,
    "legend.frameon": False,
    "savefig.dpi": 300,
    "savefig.bbox": "tight",
})

miles = mticker.FuncFormatter(lambda x, _ : f"{x:,.0f}")
libras = mticker.FuncFormatter(lambda x, _ : f"£{x:,.0f}")

def subtítulo(ax, texto):
    ax.text(0, 1.02, texto, transform=ax.transAxes, fontsize=9.5, color=GRIS_OSCURO, va="bottom")

def leyenda_mediana_mediana(ax, media, mediana, fmt):
    ax.legend(handles=[Line2D([], [], color=NEGRO, linewidth=1.5, label=f"Mediana: {fmt(mediana)}"),
                      Line2D([], [], color=NARANJA, linewidth=1.5, label=f"Media: {fmt(media)}")],
              loc="upper right", fontsize=9.5, labelcolor=NEGRO, handlelength=1.8)

# En matplotlib 3.10 cambió el parámetro para dibujar diagramas de caja horizontales
VERSION_MPL = tuple(int(v) for v in matplotlib.__version__.split(".")[2:])
HORIZONTAL = {"orientation": "horizontal"} if VERSION_MPL >= (3, 10) else {"vert": False}

def guardar(fig, nombre):
    fig.savefig(FIGURES / nombre)
    plt.show()
    print("Guardada:", (FIGURES / nombre).relative_to(ROOT).as_posix())

print("Estilo de gráficas configurado.")
```

Estilo de gráficas configurado.

## Captura 15. Figura 1. Histograma de frecuencias de Quantity

```
[15]: # Captura 15: Figura 1. Histograma de frecuencias de Quantity
p99 = df["Quantity"].quantile(0.99)
q = df.loc[df["Quantity"] <= p99, "Quantity"]
media, mediana = df["Quantity"].mean(), df["Quantity"].median()

fig, ax = plt.subplots(figsize=(9, 4.8))
ax.hist(q, bins=np.arange(0.5, p99 + 1.5, 1), color=AZUL, edgecolor="white", linewidth=0.3)
ax.axvline(mediana, color=NEGRO, linewidth=1.5)
ax.axvline(media, color=NARANJA, linewidth=1.5)
leyenda_media_mediana(ax, media, mediana, lambda v: f"{v:,.0f}" if v == int(v) else f"{v:,.2f}")
ax.set_title("Distribución de unidades por línea de venta", pad=26)
subtitulo(ax, f"Se muestra el 99 % de las líneas (Quantity ≤ {p99:,.0f}). El 1 % restante llega hasta {df['Quantity'].max():,} unidades.")
ax.set_xlabel("Unidades vendidas (Quantity)")
ax.set_ylabel("Número de líneas de venta")
ax.yaxis.set_major_formatter(miles)
ax.set_xlim(0, p99 + 1)
ax.grid(axis="x", visible=False)
guardar(fig, "fig01_histograma_quantity.png")
```



Guardada: outputs/figures/fig01\_histograma\_quantity.png

## Captura 16. Figura 2. Histograma y curva de densidad de Price

```
[16]: # Captura 16: Figura 2. Histograma y curva de densidad de Price
p99 = df["Price"].quantile(0.99)
pr = df.loc[df["Price"] <= p99, "Price"]
media, mediana = df["Price"].mean(), df["Price"].median()

fig, ax = plt.subplots(figsize=(9, 4.8))
ax.hist(pr, bins=np.arange(0, p99 + 0.25, 0.25), density=True, color='AZUL_CLARO', edgecolor="white", linewidth=0.5)
# Curva de densidad con reflexión en £0, porque no existen precios negativos
kde = stats.gaussian_kde(pr.sample(50_000, random_state=2), bw_method=0.05)
xs = np.linspace(0, p99, 600)
ax.plot(xs, kde(xs) + kde(-xs), color='AZUL', linewidth=2)
ax.axvline(mediana, color='NEGRO', linewidth=1.5)
ax.axvline(media, color='NARANJA', linewidth=1.5)
legenda_media_mediana(ax, media, mediana, lambda v: f"£{v:,.2f}")
ax.set_title("Distribución del precio unitario", pad=26)
subtitulo(ax, f"Histograma de densidad y curva de densidad estimada. Se muestra el 99 % de las líneas (precio ≤ £{p99:,.2f}).")
ax.set_xlabel("Precio unitario (£)")
ax.set_ylabel("Densidad")
ax.set_xlim(0, p99)
ax.xaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _ : f"£{x:,.0f}"))
ax.grid(axis="x", visible=False)
guardar(fig, "fig02_densidad_price.png")
```




Guardada: outputs/figures/fig02\_densidad\_price.png

## Captura 17. Figura 3. Curva de densidad de Total en escala logarítmica

```
[17]: # Captura 17: Figura 3. Curva de densidad de Total en escala Logarítmica
log_total = np.log10(df["Total"])
kde = stats.gaussian_kde(log_total.sample(50_000, random_state=2))
xs = np.linspace(log_total.min(), log_total.max(), 500)
media, mediana = df["Total"].mean(), df["Total"].median()

fig, ax = plt.subplots(figsize=(9, 4.8))
ax.fill_between(xs, kde(xs), color=AZUL, alpha=0.10, linewidth=0)
ax.plot(xs, kde(xs), color=AZUL, linewidth=2)
ax.axvline(np.log10(mediana), color=NEGRO, linewidth=1.5)
ax.axvline(np.log10(media), color=NARANJA, linewidth=1.5)
ymax = ax.get_ylim()[1]
ax.text(np.log10(mediana) - 0.05, ymax * 0.93, f"Mediana: £{mediana:,.2f}", color=NEGRO, fontsize=9, ha="right")
ax.text(np.log10(media) + 0.05, ymax * 0.93, f"Media: £{media:,.2f}", color=NEGRO, fontsize=9)
ax.set_title("Distribución del importe por línea de venta", pad=26)
subtitulo(ax, "Curva de densidad con el eje horizontal en escala logarítmica para mostrar todo el rango de valores.")
ax.set_xlabel("Importe de la línea, Total (£, escala logarítmica)")
ax.set_ylabel("Densidad de log10(Total)")
ticks = [0.1, 1, 10, 100, 1000]
ax.set_xticks(np.log10(ticks))
ax.set_xticklabels([f"£{t:,.2f}" if t < 1 else f"£{t:,.0f}" for t in ticks])
ax.set_ylim(bottom=0)
ax.annotate(f"Máx. £{df['Total'].max():,.2f}", (log_total.max(), 0), xytext=(0, 14), textcoords="offset points",
           ha="right", fontsize=8.5, color=GRIS_OSCURO)
ax.grid(axis="x", visible=False)
guardar(fig, "fig03_densidad_total.png")
```



Guardada: outputs/figures/fig03\_densidad\_total.png


## Captura 18. Figura 4. Diagramas de caja y bigotes

```
[18]: # Captura 18: Figura 4. Diagramas de caja y bigotes
etiquetas = {"Quantity": "Unidades por línea\n(Quantity)", "Price": "Precio unitario\n(£, Price)", "Total": "Importe de la línea\n(£, Total)"}

fig, axes = plt.subplots(3, 1, figsize=(9, 6.2))
for ax, v in zip(axes, VARIABLES):
    s = df[v]
    ax.boxplot(s, **HORIZONTAL, widths=0.5, whis=1.5, patch_artist=True,
               boxprops=dict(facecolor=AZUL_CLARO, edgecolor=AZUL, linewidth=1.2),
               medianprops=dict(color=NEGRO, linewidth=1.8),
               whiskerprops=dict(color=AZUL, linewidth=1.2), capprops=dict(color=AZUL, linewidth=1.2),
               flierprops=dict(marker="o", markersize=2.5, markerfacecolor=GRIS, markeredgewidth=0, alpha=0.35))
    ax.set_xscale("log")
    moneda = "" if v == "Quantity" else "£"
    ax.xaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _: m=moneda: f"{m}{x:,.2f}" if x < 1 else f"{m}{x:,.0f}"))
    ax.set_yticks([])
    ax.set_ylabel(etiquetas[v], rotation=0, ha="right", va="center", color=NEGRO, labelpad=10)
    q1, med, q3 = s.quantile([0.25, 0.5, 0.75])
    f = (lambda x: f"{x:,.0f}") if v == "Quantity" else (lambda x: f"£{x:,.2f}")
    ax.text(1.0, 0.92, f"Q1 = {f(q1)} Mediana = {f(med)} Q3 = {f(q3)} IQR = {f(q3 - q1)}",
           transform=ax.transAxes, ha="right", va="top", fontsize=8.5, color=GRIS_oscuro,
           bbox=dict(facecolor="white", edgecolor="none", pad=1))
    ax.grid(axis="y", visible=False)
axes[0].set_title("Diagramas de caja de las variables numéricas", pad=26)
subtitulo(axes[0], "Escala logarítmica, propia de cada variable. Los puntos grises son valores atípicos (más de 1.5 × IQR por encima de Q3).")
fig.tight_layout()
guardar(fig, "fig04_boxplots.png")
```

### Diagramas de caja de las variables numéricas

Escala logarítmica, propia de cada variable. Los puntos grises son valores atípicos (más de 1.5 × IQR por encima de Q3).



Guardada: outputs/figures/fig04\_boxplots.png

## Captura 19. Figura 5. Dispersión entre unidades vendidas e ingreso por producto

```
[19]: # Captura 19: Figura 5. Dispersión entre unidades vendidas e ingreso por producto
rho = productos[["Unidades", "Ingreso"]].corr(method="spearman").iloc[0, 1]
top = productos.loc[productos["Ingreso"].idxmax()]

fig, ax = plt.subplots(figsize=(9, 5.6))
ax.scatter(productos["Unidades"], productos["Ingreso"], s=14, color=AZUL, alpha=0.45, edgecolors="white", linewidths=0.4)
ax.scatter(top["Unidades"], top["Ingreso"], s=48, color=NARANJA, edgecolors="white", linewidths=1.5, zorder=3)
ax.annotate(f"Capwords({top['Description'].lower()})\n£{top['Ingreso']:,.0f} con {top['Unidades']:,} unidades",
            (top["Unidades"], top["Ingreso"]), xytext=(-12, 4), textcoords="offset points",
            bbox=dict(facecolor="white", edgecolor="none", pad=1),
            ha="right", va="center", fontsize=8.5, color=NEGRO)
ax.set_xscale("log"); ax.set_yscale("log")
ax.xaxis.set_major_formatter(miles); ax.yaxis.set_major_formatter(libras)
ax.set_title("Unidades vendidas frente a ingreso por producto", pad=26)
subtitulo(ax, f"Cada punto es uno de los {len(productos):,} productos. Ambos ejes en escala logarítmica. Correlación de Spearman: {rho:.3f}.")
ax.set_xlabel("Unidades vendidas en el periodo (escala logarítmica)")
ax.set_ylabel("Ingreso total (£, escala logarítmica)")
guardar(fig, "fig05_dispersion_unidades_ingreso.png")
```




Guardada: outputs/figures/fig05\_dispersion\_unidades\_ingreso.png

## Captura 20. Figura 6. Ingreso mensual

```
[20]: # Captura 20: Figura 6. Ingreso mensual
mensual = df.groupby(df["InvoiceDate"].dt.to_period("M")).agg(
    Ingreso=("Total", "sum"), Facturas=("Invoice", "nunique"), Unidades=("Quantity", "sum")
)
mensual.round(2).to_csv(TABLES / "monthly_sales.csv", lineterminator="\n")

MESES = ["ene", "feb", "mar", "abr", "may", "jun", "jul", "ago", "sep", "oct", "nov", "dic"]
etiquetas_mes = [f"{MESES[p.month - 1]}\n{p.year}" for p in mensual.index]
ultimo_dia = df["InvoiceDate"].max().day
colores = [AZUL] * (len(mensual) - 1) + [AZUL_CLARO]


fig, ax = plt.subplots(figsize=(10, 5))
x = np.arange(len(mensual))
ax.bar(x, mensual["Ingreso"], width=0.5, color=colores)
pico = mensual["Ingreso"].idxmax()
i_pico = list(mensual.index).index(pico)
ax.text(i_pico, mensual.loc[pico, "Ingreso"] * 1.015, f"£{mensual.loc[pico, 'Ingreso']:,.0f}", ha="center", va="bottom", fontsize=9, color=NEGRO)
ax.text(x[-1], mensual["Ingreso"].iloc[-1] * 1.015, f"Parcial:\n1 al {ultimo_dia} dic", ha="center", va="bottom", fontsize=8.5, color=GRIS_OSCURO)
ax.set_xticks(x, etiquetas_mes)
ax.yaxis.set_major_formatter(libras)
ax.set_title("Ingreso mensual por ventas de productos", pad=26)
subtitulo(ax, "Diciembre de 2011 solo incluye datos del 1 al 9, por eso su barra es más clara y no es comparable con los demás meses.")
ax.set_ylabel("Ingreso (£)")
ax.grid(axis="x", visible=False)
ax.set_ylim(0, mensual["Ingreso"].max() * 1.12)
guardar(fig, "fig06_ingreso_mensual.png")
```



Guardada: outputs/figures/fig06\_ingreso\_mensual.png

## Captura 21. Figura 7. Diez productos con mayor ingreso

```
[21]: # Captura 21: Figura 7. Diez productos con mayor ingreso
top10 = productos.nlargest(10, "Ingreso").iloc[:10]
fig, ax = plt.subplots(figsize=(9, 5.4))
y = np.arange(len(top10))
ax.barh(y, top10["Ingreso"], height=0.6, color=AZUL)
for yi, (ing, uni) in enumerate(zip(top10["Ingreso"], top10["Unidades"])):
    ax.text(ing + top10["Ingreso"].max() * 0.01, yi, f"£{ing:,.0f}", va="center", fontsize=8.5, color=NEGRO)
ax.set_yticks(y, [f"{capwords(d.lower())} ({c})" for c, d in zip(top10.index, top10["Description"])], fontsize=8.5)
ax.xaxis.set_major_formatter(libras)
ax.set_xlim(0, top10["Ingreso"].max() * 1.15)
participacion = top10["Ingreso"].sum() / productos["Ingreso"].sum() * 100
ax.set_title("Diez productos con mayor ingreso", pad=26)
subtitulo(ax, f"En conjunto generan el {participacion:.1f} % del ingreso total. Entre paréntesis, el código de producto (StockCode).")
ax.set_xlabel("Ingreso total (£)")
ax.grid(False)
ax.tick_params(axis="y", length=0)
guardar(fig, "fig07_top10_productos.png")
```




Guardada: outputs/figures/fig07\_top10\_productos.png

## Captura 22. Figura 8. Ingreso por país (sin Reino Unido)

```
[22]: # Captura 22: Figura 8. Ingreso por país (sin Reino Unido)
PAISES = {"Netherlands": "Países Bajos", "EIRE": "Irlanda", "Germany": "Alemania", "France": "Francia",
          "Australia": "Australia", "Switzerland": "Suiza", "Spain": "España", "Belgium": "Bélgica",
          "Sweden": "Suecia", "Japan": "Japón", "Norway": "Noruega", "Portugal": "Portugal",
          "Finland": "Finlandia", "Channel Islands": "Islas del Canal", "Denmark": "Dinamarca",
          "Italy": "Italia", "Cyprus": "Chipre", "Singapore": "Singapur", "Austria": "Austria"}

países = df[~df["Country"].isin(["Unspecified", "European Community"])]
países = países.groupby("Country")["Total"].sum()
países = países.sort_values(ascending=False)
# El porcentaje se calcula sobre el ingreso total, incluidas las ventas sin país identificado
países_pct = países / df["Total"].sum() * 100
países_pct.rename("Porcentaje").to_frame().join(países.rename("Ingreso")).round(4).to_csv(TABLES / "revenue_by_country.csv", lineterminator="\n")

top_países = países.drop("United Kingdom").head(10).iloc[::-1]
fig, ax = plt.subplots(figsize=(9, 5.2))
y = np.arange(len(top_países))
ax.barh(y, top_países, height=0.6, color=AZUL)
for yi, (pais, ing) in enumerate(top_países.items()):
    ax.text(ing + top_países.max() * 0.01, yi, f"£{ing:,.0f} ({pais_pct[pais]:.2f} %)", va="center", fontsize=8.5, color=NEGRO)
ax.set_yticks(y, [PAISES.get(p, p) for p in top_países.index])
ax.xaxis.set_major_formatter(libras)
ax.set_xlim(0, top_países.max() * 1.28)
ax.set_title("Diez países con mayor ingreso, sin contar al Reino Unido", pad=26)
subtitulo(ax, f"El Reino Unido concentra el {países_pct['United Kingdom']:.2f} % del ingreso total "
            f"f"£{países['United Kingdom']:.0f}) y se omite para poder comparar al resto.")
ax.set_xlabel("Ingreso total (£)")
ax.grid(axis="y", visible=False)
ax.tick_params(axis="y", length=0)
guardar(fig, "fig08_ingreso_por_pais.png")
```




Guardada: outputs/figures/fig08\_ingreso\_por\_pais.png

## Captura 23. Figura 9. Mapa de calor de la correlación de Spearman por producto

```
[23]: # Captura 23: Figura 9. Mapa de calor de La correlación de Spearman por producto
nombres = {"Unidades": "Unidades", "Facturas": "Facturas", "PrecioMediano": "Precio mediano", "Ingreso": "Ingreso"}
m = corr_productos.rename(index=nombres, columns=nombres)
cmap = "RdBu"

fig, ax = plt.subplots(figsize=(6.8, 5.6))
im = ax.imshow(m, cmap=cmap, vmin=-1, vmax=1)
for i in range(len(m)):
    for j in range(len(m)):
        val = m.iloc[i, j]
        ax.text(j, i, f"{val:.3f}", ha="center", va="center", fontsize=10,
                color="white" if abs(val) > 0.6 else NEGRO)
ax.set_xticks(range(len(m)), m.columns)
ax.set_yticks(range(len(m)), m.index)
ax.tick_params(length=0)
ax.grid(False)
for s in ax.spines.values():
    s.set_visible(False)
cb = fig.colorbar(im, ax=ax, fraction=0.046, pad=0.04)
cb.outline.set_visible(False)
cb.set_label("Coeficiente de Spearman", color=GRIS_OSCURO)
cb.ax.tick_params(color=GRIS, labelcolor=GRIS_OSCURO)
ax.set_title("Correlación de Spearman entre variables de producto", pad=26)
subtitulo(ax, "Azul: relación positiva. Rojo: relación negativa. Blanco: relación débil o nula.")
guardar(fig, "fig09_correlacion_productos.png")
```




Guardada: outputs/figures/fig09\_correlacion\_productos.png

## Captura 24. Figura 10. Concentración del ingreso por producto (curva de Pareto)

```
[24]: # Captura 24: Figura 10. Concentración del ingreso por producto (curva de Pareto)
orden = productos["Ingreso"].sort_values(ascending=False)
x_pct = np.arange(1, len(orden) + 1) / len(orden) * 100
y_pct = orden.cumsum().to_numpy() / orden.sum() * 100

fig, ax = plt.subplots(figsize=(9, 5))
ax.fill_between(x_pct, y_pct, color=AZUL, alpha=0.10, linewidth=0)
ax.plot(x_pct, y_pct, color=AZUL, linewidth=2)
x80 = n_80 / len(orden) * 100
ax.scatter([x80], [80], s=60, color=NARANJA, edgecolors="white", linewidths=2, zorder=3)
ax.annotate(f"{n_80:,} productos ({x80:.1f} %) \ngeneran el 80 % del ingreso", (x80, 80),
           xytext=(14, -26), textcoords="offset points", fontsize=9, color=NEGRO)
ax.set_xlim(0, 100); ax.set_ylim(0, 102)
ax.xaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _: f"{x:.0f} %"))
ax.yaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _: f"{x:.0f} %"))
ax.set_title("Concentración del ingreso por producto", pad=26)
subtitulo(ax, "Productos ordenados de mayor a menor ingreso. La curva muestra el porcentaje acumulado del ingreso total.")
ax.set_xlabel("Porcentaje acumulado de productos")
ax.set_ylabel("Porcentaje acumulado del ingreso")
guardar(fig, "fig10_pareto_ingreso.png")
```



Guardada: outputs/figures/fig10\_pareto\_ingreso.png

# Captura 25. Validación final de resultados

```
[25]: # Captura 25: Validación final de resultados
esperado = {
    "Filas del conjunto limpio": (len(df), 519_231),
    "Productos distintos": (df["StockCode"].nunique(), 3_790),
    "Facturas": (df["Invoice"].nunique(), 19_627),
    "Ingreso total (£)": (round(df["Total"].sum(), 2), 9_798_951.95),
    "Media de Quantity": (round(df["Quantity"].mean(), 2), 10.25),
    "Mediana de Quantity": (df["Quantity"].median(), 4),
    "Moda de Price (£)": (df["Price"].mode().iloc[0], 1.25),
    "Desviación estándar de Quantity": (round(df["Quantity"].std(), 2), 36.95),
    "IQR de Total (£)": (round(df["Total"].quantile(0.75) - df["Total"].quantile(0.25), 2), 13.80),
    "Spearman Quantity y Price": (round(spearman.loc["Quantity", "Price"], 3), -0.406),
    "Spearman facturas e ingreso por producto": (round(corr_productos.loc["Facturas", "Ingreso"], 3), 0.925),
    "Productos que generan el 80 % del ingreso": (n_80, 834),
    "Ingreso de noviembre de 2011 (£)": (round(mensual.loc[pd.Period("2011-11", "M"), "Ingreso"], 0), 1_438_321),
    "Participación de Reino Unido (%)": (round(pais_pct["United Kingdom"], 2), 84.80),
    "Gráficas generadas": (len(list(FIGURES.glob("fig*.png"))), 10),
}
validacion = pd.DataFrame([(k, float(v[0]), float(v[1]), bool(np.isclose(v[0], v[1])) for k, v in esperado.items()]),
    columns=["Concepto", "Obtenido", "Esperado", "Coincide"])
formato = lambda v: f"{v:,.0f}" if float(v).is_integer() else (f"{v:,.3f}" if abs(v) < 1 else f"{v:,.2f}")
display(validacion.style.format({"Obtenido": formato, "Esperado": formato}).hide(axis="index"))
assert validacion["Coincide"].all(), "Hay resultados que no coinciden con los esperados"
print("Todas las cifras del análisis coinciden con las esperadas.")
```

| Concepto                                  | Obtenido     | Esperado     | Coincide |
|-------------------------------------------|--------------|--------------|----------|
| Filas del conjunto limpio                 | 519,231      | 519,231      | True     |
| Productos distintos                       | 3,790        | 3,790        | True     |
| Facturas                                  | 19,627       | 19,627       | True     |
| Ingreso total (£)                         | 9,798,951.95 | 9,798,951.95 | True     |
| Media de Quantity                         | 10.25        | 10.25        | True     |
| Mediana de Quantity                       | 4            | 4            | True     |
| Moda de Price (£)                         | 1.25         | 1.25         | True     |
| Desviación estándar de Quantity           | 36.95        | 36.95        | True     |
| IQR de Total (£)                          | 13.80        | 13.80        | True     |
| Spearman Quantity y Price                 | -0.406       | -0.406       | True     |
| Spearman facturas e ingreso por producto  | 0.925        | 0.925        | True     |
| Productos que generan el 80 % del ingreso | 834          | 834          | True     |
| Ingreso de noviembre de 2011 (£)          | 1,438,321    | 1,438,321    | True     |
| Participación de Reino Unido (%)          | 84.80        | 84.80        | True     |
| Gráficas generadas                        | 10           | 10           | True     |

Todas las cifras del análisis coinciden con las esperadas.